Análisis de técnicas ofensivas contra modelos de lenguaje: jailbreaking, envenenamiento de datos y ataques adversariales

Antonio De Mateo Bodegas · U-TAD · Técnicas de investigación de la ciberseguridad · Primera entrega: Memoria · Oct 13, 2026

Presentación

El objeto de estudio son las tres grandes familias de ataques ofensivos contra los modelos de lenguaje (LLM) actuales: el jailbreaking, el envenenamiento de datos (data poisoning) y los ataques adversariales. El eje principal será el jailbreaking, al que dedicaré más tiempo; las otras dos familias se estudiarán con la profundidad necesaria para entenderlas por sí mismas y relacionarlas con él. El trabajo será íntegramente teórico y consistirá en revisar y ordenar la literatura y las charlas técnicas existentes para entender cómo funcionan estos ataques, por qué funcionan y qué revelan sobre los límites de seguridad de estos modelos.

Ámbito

La investigación se sitúa en el ámbito ofensivo. El objeto de estudio son técnicas de ataque contra modelos de lenguaje, analizadas desde la perspectiva de quien las ejecuta: cómo se construyen, en qué condiciones tienen éxito y por qué.

No obstante, el trabajo incorpora de forma deliberada un componente defensivo. No es posible entender por qué un jailbreak funciona sin entender antes qué mecanismo de seguridad pretende sortear, de modo que cada familia de ataque se estudiará junto a las defensas que intenta vencer. Esta doble mirada es, además, la práctica habitual en la disciplina: los equipos de red teaming atacan sus propios modelos precisamente para reforzarlos, como muestra una de las charlas analizadas sobre el proceso de seguridad de Llama 3.

El trabajo no pertenece al ámbito de respuesta a incidentes ni al forense. No se analizan evidencias tras un incidente real, ni discos, memoria o artefactos de una intrusión: el foco está en la técnica de ataque y su fundamento, no en la investigación posterior a un compromiso.

Descripción de la investigación

Pregunta de investigación

¿Qué técnicas permiten alterar el comportamiento de los modelos de lenguaje actuales — jailbreaking, envenenamiento de datos y ataques adversariales—, por qué funcionan y qué revelan sobre los límites de seguridad de estos modelos?

Objetivo general

Comprender en profundidad las tres familias de ataque ofensivo contra LLM y producir un análisis estructurado que explique, para cada una, su mecanismo, sus variantes, sus condiciones de éxito y las defensas conocidas.

Objetivos específicos

1. Entender cómo funciona por dentro un modelo de lenguaje y cómo se le dota de seguridad, como base necesaria para todo lo demás.
2. Catalogar y explicar las principales técnicas de jailbreaking y las razones por las que el entrenamiento de seguridad falla ante ellas.
3. Explicar el envenenamiento de datos y, en particular, las puertas traseras (backdoors): cómo se introducen y por qué son difíciles de detectar.
4. Situar los ataques adversariales, con énfasis en su variante sobre texto, y relacionarlos con las dos familias anteriores.
5. Recoger, para cada familia, las defensas y los métodos de detección documentados.
6. Integrar todo en un documento final ordenado por familias que sirva como análisis de referencia.

Hipótesis de partida

H1 (común a las tres familias). Los tres tipos de ataque comparten una causa raíz: los modelos de lenguaje responden sobre todo a la forma superficial de la entrada, y no a su intención, lo que los hace manipulables sin necesidad de acceder a su interior.

H2 (jailbreaking). El entrenamiento de seguridad enseña al modelo a rechazar patrones concretos, no intenciones, por lo que reformular una petición (con un juego de rol, en otro idioma o repartida en varios turnos) basta a menudo para sortearlo. Además, los modelos más capaces, al seguir mejor las instrucciones, no son necesariamente más resistentes a este tipo de ataques.

H3 (envenenamiento de datos). Basta una cantidad pequeña de datos manipulados para introducir una puerta trasera en un modelo, con independencia de su tamaño, y esa puerta trasera es difícil de detectar y de eliminar con el entrenamiento de seguridad

habitual.

H4 (ataques adversariales). Las perturbaciones de texto encontradas de forma automática contra un modelo se transfieren con frecuencia a otros modelos distintos, lo que convierte el ataque adversarial sobre texto en una forma de jailbreak automatizado.

Todas las hipótesis se contrastarán con la literatura y las charlas a lo largo del trimestre. H1 y H2 tendrán más peso, en coherencia con el eje principal del trabajo.

Motivación

El interés por este tema nace de dos sitios. Por un lado, la presencia constante en redes y medios de los avances en inteligencia artificial, un campo que evoluciona muy rápido y cuyos riesgos de seguridad todavía se están entendiendo. Por otro, mi propio interés por la ciberseguridad, en la que quiero especializarme.

Como estudiante de Ingeniería del Software ya tengo una idea general de cómo funciona un modelo de lenguaje, pero quiero pasar de esa idea general a una comprensión profunda: entender de verdad cómo se comporta un modelo por dentro, por qué se le puede manipular y dónde están sus límites. Estudiar los ataques es, para mí, la vía más directa para entender la tecnología, porque los fallos muestran el funcionamiento real mejor que la teoría. El resultado que busco es doble: aprender lo máximo posible sobre estos modelos y dejarlo recogido en un análisis ordenado que me sirva de base para seguir profundizando.

Alcance

Qué se va a analizar

- Las tres familias de ataque sobre modelos de lenguaje: jailbreaking, envenenamiento de datos (incluidas las puertas traseras) y ataques adversariales en su variante de texto. El jailbreaking es el eje principal y el que recibirá más dedicación.
- Como referencia principal, los tres modelos comerciales más potentes y extendidos en la actualidad: Claude (Anthropic), ChatGPT/GPT (OpenAI) y Gemini (Google). Se citarán también modelos abiertos cuando la literatura los use como objeto de estudio, como Llama.
- Las defensas y los métodos de detección asociados a cada familia, a nivel panorámico.

Qué queda expresamente fuera

- Los ataques adversariales sobre imagen y audio, que solo se mencionarán como rama paralela; el trabajo se centra en el texto.

- Los ataques a la infraestructura y la cadena de suministro de los modelos (fallos en los formatos de archivo, deserialización y similares). Se recogen como contexto a partir de una de las charlas, pero no son el núcleo del estudio.
- El desarrollo de herramientas nuevas y cualquier contribución práctica: el trabajo es teórico.
- La generación real de contenido dañino. El estudio se limita al mecanismo de los ataques, no a producir resultados peligrosos.
- El entrenamiento real de modelos y cualquier prueba sobre modelos a los que no se tenga acceso legítimo.

Estado del arte

El estudio de los ataques contra modelos de lenguaje es un campo muy activo, con publicaciones recientes en congresos académicos (USENIX Security, IEEE S&P, NeurIPS) y en conferencias de la comunidad de seguridad (DEF CON). La base de partida son seis charlas técnicas de 2024–2025, analizadas en un trabajo previo de esta misma asignatura, y un conjunto de artículos de referencia. Aquí solo se mencionan; su revisión a fondo forma parte del trabajo que se hará durante el trimestre.

Charlas de partida

- Hackin' AI: Creando una IA… ¿Qué puede salir mal? (Chema Alonso, OpenExpo Europe, 2025). Visión divulgativa de los riesgos de seguridad de la IA; trata el envenenamiento de datos y el jailbreak mediante juego de rol.
- Don't Listen To Me (Yu et al., USENIX Security 2024). Clasifica jailbreaks reales recogidos de internet y estudia cómo los crean las personas.
- LLM-Fuzzer (Yu et al., USENIX Security 2024). Genera jailbreaks de forma automática mediante fuzzing.
- Taming the Beast: Inside the Llama 3 Red Team Process (Meta, DEF CON 32, 2024). Cómo un equipo de red teaming ataca su propio modelo para reforzarlo antes de lanzarlo.
- Instruction Backdoor Attacks Against Customized LLMs (Zhang et al., USENIX Security 2024). Puertas traseras escondidas en las instrucciones de modelos personalizados, sin tocar los datos de entrenamiento.
- Incubated Machine Learning Exploits (Suha Sabi Hussain, DEF CON 32, 2024). Puertas traseras introducidas aprovechando fallos en los archivos donde se guardan los modelos.

Artículos de referencia

- Marco general: el informe NIST AI 100-2e2025 (2025) ofrece una taxonomía común de ataques a sistemas de IA que incluye las tres familias de este trabajo.
- Jailbreaking: Wei et al. (2023) explican por qué falla el entrenamiento de seguridad; Anil et al. (2024) describen el many-shot jailbreaking, que aprovecha las conversaciones largas.
- Envenenamiento de datos: Carlini et al. (2024) muestran que envenenar datos de entrenamiento a escala web es viable; Hubinger et al. (2024) que una puerta trasera puede sobrevivir al entrenamiento de seguridad; y un estudio de Anthropic con el UK AI Security Institute y el Alan Turing Institute (2025) que unos 250 documentos manipulados bastan para introducir una puerta trasera en modelos de 600 millones a 13.000 millones de parámetros.
- Ataques adversariales: Goodfellow et al. (2015) sientan la base sobre imágenes, y Zou et al. (2023) trasladan la idea al texto con sufijos generados automáticamente que actúan como jailbreak.

Qué aporta esta investigación

La mayoría de estos trabajos se centran en una sola familia y en un resultado concreto. La aportación de este proyecto no será un ataque nuevo, sino una revisión ordenada que relacione las tres familias bajo una causa común y recoja, para un lector no experto, su mecanismo, sus variantes y sus defensas.

Sistemas objeto de la investigación y cobertura legal

Sistemas y acceso

Los sistemas objeto de estudio son los tres modelos de lenguaje comerciales ya citados: Claude, ChatGPT/GPT y Gemini. Conviene distinguir dos niveles de acceso, porque condicionan qué se puede estudiar y cómo:

- Inferencia (uso del modelo ya entrenado). Tengo acceso legítimo a la interfaz pública de los tres modelos, lo que permite, si procede, observar su comportamiento ante distintas formulaciones. Este es el nivel relevante para la familia de jailbreaking.
- Entrenamiento (datos y pesos del modelo). No tengo acceso al proceso de entrenamiento ni a los pesos internos de ninguno de estos modelos. Por tanto, el envenenamiento de datos y las puertas traseras se estudiarán exclusivamente a partir de la literatura, no de forma experimental sobre estos modelos.

Como el trabajo es teórico, no se reproduce ningún sistema en laboratorio en sentido estricto. Por laboratorio se entiende aquí un entorno controlado y aislado —mi propio equipo y las interfaces oficiales de los modelos— en el que, de hacerse alguna comprobación puntual, se haría sin afectar a terceros. Si en algún momento quisiera observar el comportamiento de un modelo sobre mi propio hardware, usaría un modelo abierto y pequeño ejecutado en local, lo que evitaría cualquier dependencia de servicios de terceros.

Cobertura legal de las pruebas

Dado el carácter teórico del trabajo, el riesgo legal es mínimo, pero se fijan igualmente estos límites:

- Solo se interactúa con modelos a los que tengo acceso legítimo, respetando sus términos de uso.
- Las comprobaciones, si las hay, se limitan a entender el mecanismo con ejemplos inocuos; no se busca ni se difunde contenido realmente dañino.
- No se ataca ningún sistema de terceros ni se accede a datos o modelos ajenos.
- Las evidencias de carácter ilustrativo (capturas, registros) se usarían solo para mi comprensión y no forman parte de la entrega.

Material hardware y software

Lo que ya tengo

- Hardware: mi ordenador personal, suficiente para un trabajo de revisión documental.
- Software y accesos: acceso a los tres modelos (Claude, ChatGPT y Gemini) a través de sus interfaces; navegador; una herramienta de gestión de documentos y notas; y acceso a los repositorios públicos donde está la literatura (arXiv, la biblioteca de USENIX y los vídeos de las charlas).

Lo que falta o es opcional

Para la parte teórica no se necesita adquirir nada. A modo opcional, y solo si se quisiera observar un modelo sobre el propio equipo sin recurrir a servicios de terceros, se podría instalar un modelo abierto y pequeño en local (por ejemplo, mediante un ejecutor de modelos tipo Ollama). No es imprescindible para cumplir los objetivos.

Metodología

El método será una revisión documental sistemática, organizada por las tres familias de ataque y construida por capas, de lo básico a lo específico. Lo que sigue es el plan previsto, que se pondrá en marcha tras esta entrega.

Fases

1. Fundamentos (mes 1). Entender cómo funciona un LLM y cómo se le dota de seguridad, y trazar el panorama general de ataques.
2. Jailbreaking (mes 2). Estudiar sus variantes, por qué funcionan, su automatización y sus defensas.
3. Envenenamiento y cierre (mes 3). Estudiar el data poisoning y las puertas traseras, los ataques adversariales de texto y las defensas; cerrar con la síntesis comparada y las conclusiones.

Herramientas

Se trabajará con artículos y actas de congresos (arXiv, USENIX), charlas en vídeo, las interfaces de los modelos para observaciones puntuales y un asistente de IA como apoyo en redacción y estructura (ver el último apartado).

Evidencias que se recogerán

- Un documento de apuntes por familia (jailbreaking, data poisoning, adversariales), actualizado cada semana con lo nuevo leído y resumido con mis palabras.
- Una ficha por fuente (charla o artículo) con sus datos, su idea principal y su relación con el tema.
- El documento final que integra y ordena todo.

Criterios para considerar cumplido cada objetivo

- Un concepto se da por aprendido cuando soy capaz de explicarlo con mis propias palabras sin recurrir a la fuente.
- Una familia se da por cubierta cuando su apartado recoge mecanismo, variantes principales, condiciones de éxito y defensas, con cada afirmación respaldada por al menos una fuente.
- Una hipótesis se da por contrastada cuando puedo argumentar, apoyándome en las fuentes, si se sostiene o no.
- El trabajo se da por terminado cuando el documento final cubre las tres familias y responde a la pregunta de investigación.

Hitos y cronograma

El trabajo se repartirá en doce semanas agrupadas en tres bloques mensuales. Cada semana terminará con una evidencia concreta (apuntes o fichas), y cada bloque cerrará un hito. Las fechas son orientativas y se ajustarán al calendario oficial de entregas de la asignatura.

Semana	Fechas	Trabajo	Evidencia
S1	13–19 oct	Cómo funciona un LLM: tokens, entrenamiento, inferencia	Apuntes: fundamentos
S2	20–26 oct	Cómo se hace seguro un modelo: alineamiento, RLHF, filtros	Apuntes: seguridad
S3	27 oct–2 nov	Panorama de ataques a LLM; situar las tres familias	Mapa general
S4	3–9 nov	Integrar las seis charlas con los conceptos ya claros	Fichas revisadas
S5	10–16 nov	Jailbreaking: primeros casos y por qué funcionan	Apuntes jailbreak I
S6	17–23 nov	Familias de jailbreak: rol, camuflaje, varios turnos	Apuntes jailbreak II
S7	24–30 nov	Jailbreaks automáticos y adversariales de texto	Apuntes jailbreak III
S8	1–7 dic	Defensas frente al jailbreaking	Apuntes defensas I
S9	8–14 dic	Data poisoning: qué es y de dónde salen los datos	Apuntes poisoning I
S10	15–21 dic	Puertas traseras (backdoors)	Apuntes poisoning II
S11	8–14 ene	Defensas y detección de envenenamiento	Apuntes defensas II
S12	15–21 ene	Síntesis comparada, ética y conclusiones	Documento final

Hitos: fin del mes 1 (S4), fundamentos y charlas integradas; fin del mes 2 (S8), familia de jailbreaking cerrada; fin del mes 3 (S12), documento final completo. Se prevé una pausa en torno a las fechas navideñas (22 dic–7 ene) entre las semanas S10 y S11.

Plan de uso de IA

Herramienta. Usaré Claude como apoyo durante todo el trabajo; también lo he usado para preparar esta memoria.

Tareas que delego en la IA

- Ayuda para redactar de forma clara y formal a partir de mis apuntes e ideas.
- Ayuda para ordenar y estructurar los contenidos.
- Explicación de términos técnicos, sobre todo de las fuentes en inglés, que no domino en ese idioma.
- Localización de fuentes y lecturas candidatas, que después reviso yo.

Tareas que reservo sin IA

- La elección del tema, del enfoque y de las fuentes.
- El visionado y la lectura de las fuentes y la toma de mis propios apuntes.
- La decisión sobre qué entra y qué queda fuera, y las conclusiones.
- La revisión final de todo el texto.

Verificación de resultados

- Toda afirmación técnica se contrasta con la fuente original (artículo o charla) antes de darla por buena.
- Los datos concretos (autoría, cifras, años, lugar de publicación) se comprueban en las páginas oficiales de los congresos o en los propios artículos.
- No se da por válido ningún resumen de la IA que no pueda rastrear hasta una fuente.